

MBA em Ciências de Dados

Sistemas de Recomendação: Uma Abordagem Sobre Jogos de Tabuleiro Modernos

Autor: Isabelly da Silva Almeida

Orientador: Adriano Kamimura Suzuki



Introdução

Contexto e Motivação

- ▶ Crescimento dos jogos de tabuleiro modernos nas últimas décadas
- ▶ Ampliação do público e diversidade de perfis de jogadores
- ▶ Contribuições educacionais, sociais e cognitivas
- ▶ Excesso de opções dificulta a escolha de novos jogos

Problema e Objetivos

Problema

Como auxiliar usuários na descoberta de jogos de tabuleiro alinhados às suas preferências em um cenário de grande volume de opções?

Objetivo do Trabalho

Avaliar e comparar diferentes abordagens de sistemas de recomendação aplicadas ao contexto de jogos de tabuleiro modernos, utilizando dados reais da plataforma *BoardGameGeek*.

Metodologia

O que são Sistemas de Recomendação

Sistemas de recomendação são ferramentas computacionais projetadas para auxiliar usuários na descoberta de itens de interesse em ambientes com grande volume de opções.

Objetivos dos Sistemas de Recomendação

Os principais objetivos dos sistemas de recomendação incluem:

- ▶ Sugerir itens relevantes de acordo com o perfil do usuário
- ▶ Melhorar a experiência e satisfação do usuário
- ▶ Aumentar o engajamento com a plataforma
- ▶ Auxiliar na descoberta de novos itens

Tipos e Abordagens de Sistemas de Recomendação

Diferentes abordagens podem ser adotadas na construção de sistemas de recomendação, cada uma com características específicas.

- ▶ Filtragem Colaborativa
- ▶ Sistemas Baseados em Conteúdo
- ▶ Modelos Baseline
- ▶ Sistemas Híbridos

Filtragem Colaborativa

A filtragem colaborativa explora padrões de avaliação entre usuários e itens, assumindo que usuários com comportamentos semelhantes tendem a compartilhar preferências.

O problema é modelado por uma matriz de avaliações $R \in \mathbb{R}^{|U| \times |I|}$, onde r_{ui} representa a avaliação do usuário u para o item i .

A matriz R é tipicamente esparsa.

Filtragem Colaborativa: Predição e Top-k

A predição da avaliação é realizada a partir dos k vizinhos mais similares (Top- k):

$$\hat{r}_{ui} = \bar{r}_u + \frac{\sum_{v \in N_k(u)} \text{sim}(u, v) (r_{vi} - \bar{r}_v)}{\sum_{v \in N_k(u)} |\text{sim}(u, v)|}$$

Vantagens

- ▶ Boa capacidade de capturar padrões coletivos

Desvantagens

- ▶ Sensível à esparsidade e ao problema de *cold-start*

Sistemas Baseados em Conteúdo

Os sistemas baseados em conteúdo recomendam itens semelhantes àqueles previamente avaliados pelo usuário, utilizando características descritivas dos itens.

A predição é obtida considerando os k itens mais similares:

$$\hat{r}_{ui} = \frac{\sum_{j \in N_k(i)} \text{sim}(i, j) r_{uj}}{\sum_{j \in N_k(i)} |\text{sim}(i, j)|}$$

Vantagens

- ▶ Menor impacto do *cold-start* de itens

Desvantagens

- ▶ Dependência da qualidade dos atributos dos itens

Modelo Baseline

O modelo baseline fornece uma estimativa simples das avaliações, considerando efeitos globais e individuais:

$$\hat{r}_{ui} = \mu + b_u + b_i$$

Objetivo

- ▶ Servir como referência mínima de desempenho

Vantagens

- ▶ Simples e computacionalmente eficiente

Desvantagens

- ▶ Não captura interações complexas entre usuários e itens

Modelo Híbrido

Os sistemas híbridos combinam diferentes abordagens de recomendação, buscando explorar suas vantagens complementares.

$$\hat{r}_{u,i}^{(H)} = \beta \hat{r}_{u,i}^{(SR_1)} + (1 - \beta) \hat{r}_{u,i}^{(SR_2)}, \text{ onde } \beta \in [0, 1]$$

- ▶ Integra duas abordagens distintas
- ▶ Reduz limitações individuais dos modelos

Medidas de Similaridade

As medidas de similaridade variam conforme o tipo de sistema de recomendação.

- ▶ **Correlação de Pearson:** adequada para filtragem colaborativa
- ▶ **Similaridade do Cosseno:** utilizada em vetores de atributos
- ▶ **Distância Euclidiana:** sensível à magnitude das avaliações
- ▶ **Coeficiente de Jaccard:** apropriado para dados binários

Métricas de Avaliação — Acurácia

Avaliam o erro entre os valores reais observados e as previsões geradas pelos modelos.

Erro Médio Absoluto (MAE)

$$\text{MAE} = \frac{1}{N} \sum |r_{ui} - \hat{r}_{ui}|,$$

penaliza todos os desvios de forma linear mantendo a unidade original da variável analisada.

Raiz do Erro Quadrático Médio (RMSE)

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum (r_{ui} - \hat{r}_{ui})^2},$$

Atribui maior peso a erros de grande magnitude, sendo sensível a previsões muito distantes dos valores reais.

Métricas de Avaliação — Ranqueamento

Avaliam a capacidade do modelo em priorizar corretamente os itens mais relevantes entre as primeiras posições da recomendação.

Precision@k

$$\text{Precision@k} = \frac{|\text{itens relevantes} \cap \text{top-}k|}{k},$$

Indica a proporção de itens relevantes entre os k primeiros recomendados, refletindo a qualidade do topo da lista.

Recall@k

$$\text{Recall@k} = \frac{|\text{itens relevantes} \cap \text{top-}k|}{|\text{itens relevantes}|}$$

Mede a capacidade do modelo em recuperar os itens relevantes disponíveis, considerando o conjunto total de itens de interesse do usuário.

Dados

Base de Dados

- ▶ Fonte: plataforma *BoardGameGeek*
- ▶ Base amplamente utilizada em estudos sobre jogos de tabuleiro
- ▶ Dados compostos por:
 - ▶ Avaliações de usuários para jogos
 - ▶ Informações descritivas dos jogos (categorias e mecânicas)
- ▶ Estrutura típica de recomendação: matriz usuário-jogo

Resultados




Implementação e Análise Prática

Este capítulo apresenta os resultados obtidos a partir da implementação dos modelos de recomendação descritos na metodologia.

- ▶ Análise exploratória e pré-processamento dos dados
- ▶ Definição da matriz de avaliações
- ▶ Treinamento, parametrização e avaliação dos modelos


Distribuição das Notas

A distribuição das avaliações permite compreender o comportamento geral das notas atribuídas pelos usuários.




Distribuição de Avaliações por Usuário

A maioria dos usuários avalia apenas um número reduzido de jogos, o que contribui para a esparsidade da base.



Distribuição de Avaliações por Jogo

Observa-se concentração de avaliações em um subconjunto reduzido de jogos, indicando assimetria de popularidade.



Matriz de Avaliações R

Após o pré-processamento, os dados são organizados em uma matriz usuário–jogo R , utilizada como base para os modelos de recomendação.


- ▶ Linhas representam usuários
- ▶ Colunas representam jogos
- ▶ Entradas correspondem às avaliações observadas

Divisão dos Dados em Treino e Teste


Os experimentos foram conduzidos por meio de uma divisão dos dados em conjuntos de treinamento e teste.

- ▶ Avaliação realizada em cenário offline
- ▶ Garantia de comparabilidade entre os modelos

Filtragem Colaborativa — Sensibilidade ao Top-k (Acurácia)




RMSE




MAE

Filtragem Colaborativa — Sensibilidade ao Top-k (Ranking)




Precision@k




Recall@k

Baseado em Conteúdo — Sensibilidade ao Top-k (Acurácia)




RMSE




MAE

Baseado em Conteúdo — Sensibilidade ao Top-k (Ranking)



Precision@k



Recall@k

Modelo Baseline — Resultados

O modelo baseline é utilizado como referência mínima de desempenho, permitindo avaliar os ganhos obtidos pelos modelos mais complexos.

Modelo	RMSE	MAE	Precision@k	Recall@k
Baseline	1,1141	0,8352	0,8489	0,1721

- ▶ Não depende de vizinhança nem de parâmetros
- ▶ Serve como linha de base para comparação

Desempenho dos Modelos Individuais

Modelo	RMSE	MAE	P@10	R@10
FC User–User (Pearson, $K = 50$)	1,0895	0,8159	0,8709	0,1781
Baseline ($\mu + b_u + b_i$)	1,1141	0,8352	0,8489	0,1721
BC Item–Item (Jaccard, $K = 30$)	1,1865	0,8877	0,7917	0,1595

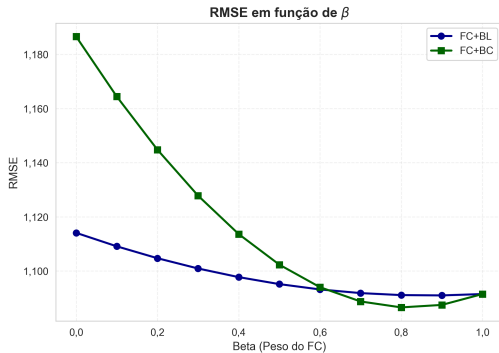
Limitações dos Modelos Individuais

- ▶ **Filtragem Colaborativa**
 - ▶ Melhor desempenho preditivo
 - ▶ Sensível à esparsidade e ao *cold-start*
- ▶ **Baseline**
 - ▶ Estável e computacionalmente eficiente
 - ▶ Baixa capacidade de personalização
- ▶ **Baseado em Conteúdo**
 - ▶ Maior cobertura do sistema
 - ▶ Desempenho preditivo inferior


Estratégia de Integração Híbrida

- ▶ Nenhuma abordagem isolada garante robustez em cenários reais.
- ▶ Proposta: combinar modelos para explorar vantagens complementares.
- ▶ Modelos implementados:
 - ▶ **FC + BL**
 - ▶ **FC + BC**
- ▶ Objetivos:
 - ▶ Melhorar desempenho preditivo
 - ▶ Reduzir efeitos do *cold-start*
 - ▶ Aumentar estabilidade das recomendações

Modelo Híbrido — Sensibilidade ao Parâmetro β (Acurácia)

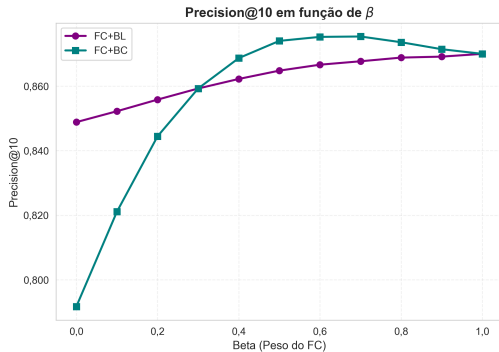


RMSE




MAE

Modelo Híbrido — Sensibilidade ao Parâmetro β (Ranking)



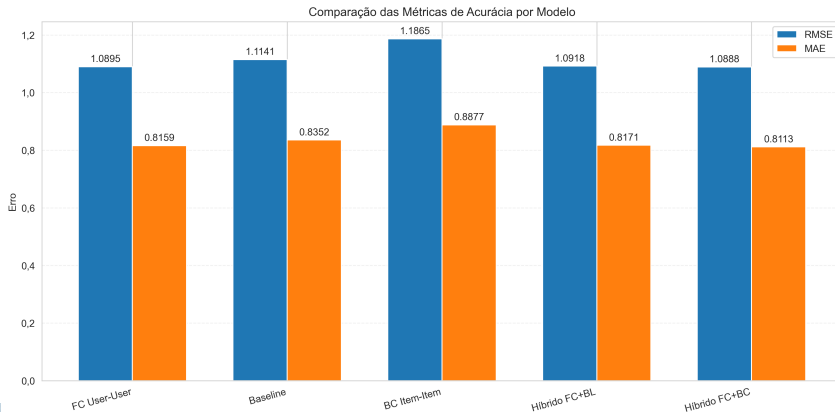
Precision@k



Recall@k


Comparação Final — Acurácia

A comparação entre os modelos evidencia diferenças no desempenho preditivo segundo as métricas de acurácia.



Comparação Final — Ranqueamento

As métricas de ranqueamento permitem avaliar a qualidade das listas de recomendação geradas pelos modelos.



Conclusão



Conclusão

A avaliação conjunta de erro e ranqueamento indica que o modelo híbrido FC+BC ($\beta = 0,7$) apresenta o melhor compromisso entre desempenho e aplicabilidade.

- ▶ Erros preditivos (MAE e RMSE) competitivos,
- ▶ Redução do problema de *cold-start* via componente Baseado em Conteúdo,
- ▶ Melhor qualidade do ranking (Precision@10 e Recall@10).

Limitações e Trabalhos Futuros

- ▶ Avaliação restrita a ambiente offline
- ▶ Baseline heurístico por limitações computacionais
- ▶ Extensão para Baseline regularizado ou Fatoração de Matrizes
- ▶ Enriquecimento do conteúdo dos itens (atributos adicionais)

Obrigada!